

Particle Swarm Optimization: Um Estudo sobre o Algoritmo PSO

César Eduardo de Souza¹,
Guilherme Diel¹

¹Departamento de Ciência da Computação
Universidade do Estado de Santa Catarina (UDESC) – Joinville, SC – Brasil

{cesar.souza, guilherme.diel}@edu.udesc.br

Resumo. Algoritmos heurísticos são fundamentais na busca por soluções satisfatórias para problemas complexos de otimização. Um dos métodos mais populares é o **Particle Swarm Optimization** (PSO), inspirado no comportamento coletivo de enxames naturais. Este algoritmo é capaz de resolver problemas NP-Hard e NP-Completo, como funções de benchmark em otimização contínua. Neste trabalho, é apresentada uma implementação do PSO para otimização das funções de Ackley e Griewank, analisando-se seu desempenho em diferentes dimensões e discutindo-se possíveis aplicações futuras e comparações com outras abordagens.

1. Introdução

A busca por soluções eficientes para problemas de otimização combinatória e contínua motivou o desenvolvimento de diversos algoritmos heurísticos e metaheurísticos. Entre esses, destaca-se o **Particle Swarm Optimization** (PSO), proposto por Kennedy e Eberhart em 1995, inspirado no comportamento social de pássaros e cardumes [Kennedy and Eberhart 1995].

O PSO tem ampla aplicação na resolução de problemas de otimização devido à sua simplicidade, facilidade de implementação e capacidade de convergir para soluções de alta qualidade. O algoritmo baseia-se em um conjunto de partículas (soluções candidatas) que exploram o espaço de busca, ajustando suas posições com base em suas experiências individuais e no conhecimento coletivo do grupo.

Este trabalho investiga o desempenho do PSO na otimização das funções de Ackley e Griewank, ambas amplamente utilizadas como benchmarks em otimização contínua. Avalia-se o comportamento do algoritmo em diferentes dimensões e discute-se os resultados obtidos.

Este relatório está organizado da seguinte forma: a Seção 2 apresenta a metodologia e a descrição do algoritmo PSO. A Seção 3 aborda os experimentos realizados e os resultados obtidos. A Seção 4 discute a análise dos resultados. Por fim, a Seção 5 apresenta as conclusões e propostas de trabalhos futuros.

2. Metodologia de Desenvolvimento

O algoritmo **Particle Swarm Optimization** (PSO) opera conforme os seguintes passos:

1. Inicializar uma população de partículas com posições e velocidades aleatórias no espaço de busca.

2. Avaliar a função objetivo para cada partícula na posição atual.
3. Atualizar a melhor posição individual ($pbest$) e a melhor posição global ($gbest$).
4. Atualizar a velocidade e a posição de cada partícula com base nas equações:

$$v_i(t+1) = wv_i(t) + c_1r_1(pbest_i - x_i(t)) + c_2r_2(gbest - x_i(t)) \quad (1)$$

$$x_i(t+1) = x_i(t) + v_i(t+1) \quad (2)$$

onde w representa o fator de inércia, c_1 e c_2 são os coeficientes cognitivo e social, e r_1, r_2 são números aleatórios em $[0, 1]$.

5. Repetir os passos 2 a 4 até atingir um critério de parada (número máximo de iterações ou tolerância de erro).

A implementação foi realizada em *Python*, utilizando a biblioteca *NumPy* para operações vetoriais e *Matplotlib* para visualização dos resultados.

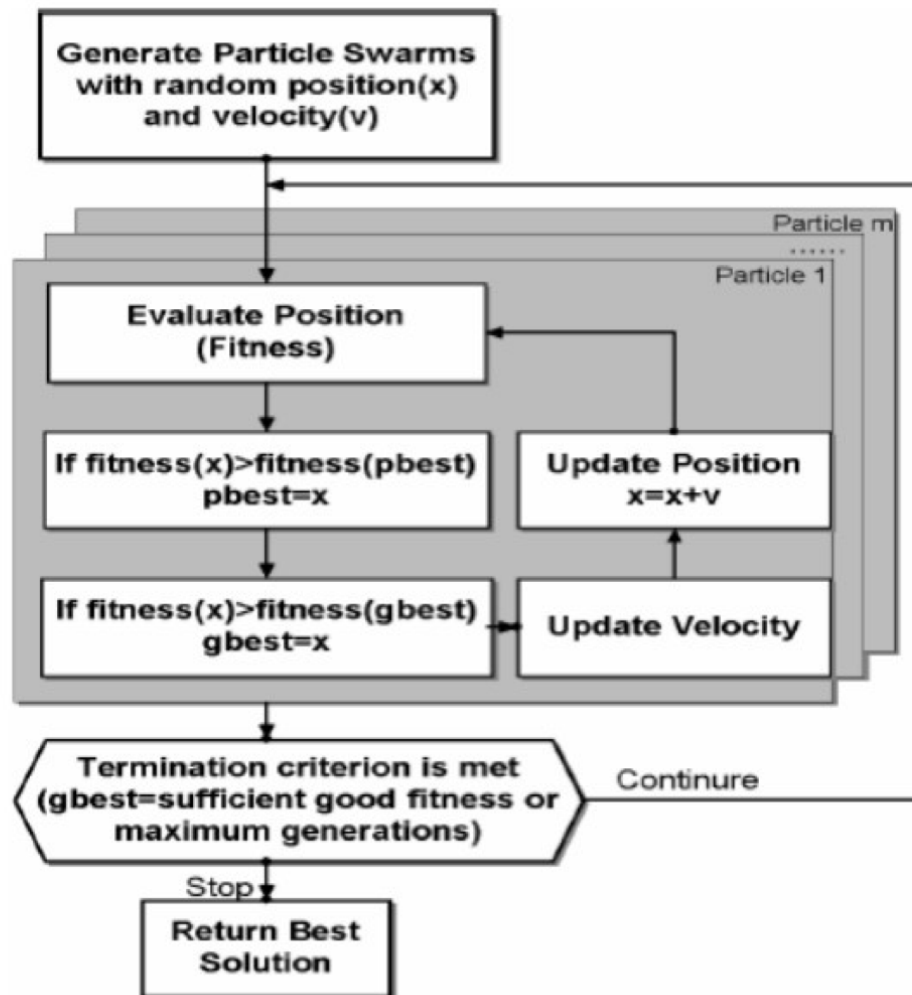


Figura 1. Diagrama do algoritmo Particle Swarm Optimization

3. Descrição dos Experimentos e Resultados Obtidos

Os experimentos foram realizados com as funções de Ackley e Griewank, adotando as seguintes configurações:

- Número de partículas: 30
- Dimensões: 5 e 10
- Número de execuções: 10 por configuração
- Parâmetros: $c_1 = c_2 = 2,05$, fator de inércia $w = 0,7$
- Critério de parada: tolerância $1 \cdot 10^{-10}$ ou número máximo de iterações

As Figuras 2 e 3 mostram os gráficos de convergência da média do fitness para a função Ackley em 5 e 10 dimensões, respectivamente.




Figura 2. Convergência do PSO para Ackley (5 dimensões)




Figura 3. Convergência do PSO para Ackley (10 dimensões)

As Figuras 4 e 5 apresentam os resultados para a função Griewank.




Figura 4. Convergência do PSO para Griewank (5 dimensões)




Figura 5. Convergência do PSO para Griewank (10 dimensões)

Os resultados demonstram que o PSO foi capaz de encontrar soluções próximas ao ótimo global para ambas as funções, com desempenho superior em instâncias de menor dimensionalidade.

A seguir, apresentam-se os boxplots com os valores obtidos em 30 execuções para cada configuração:

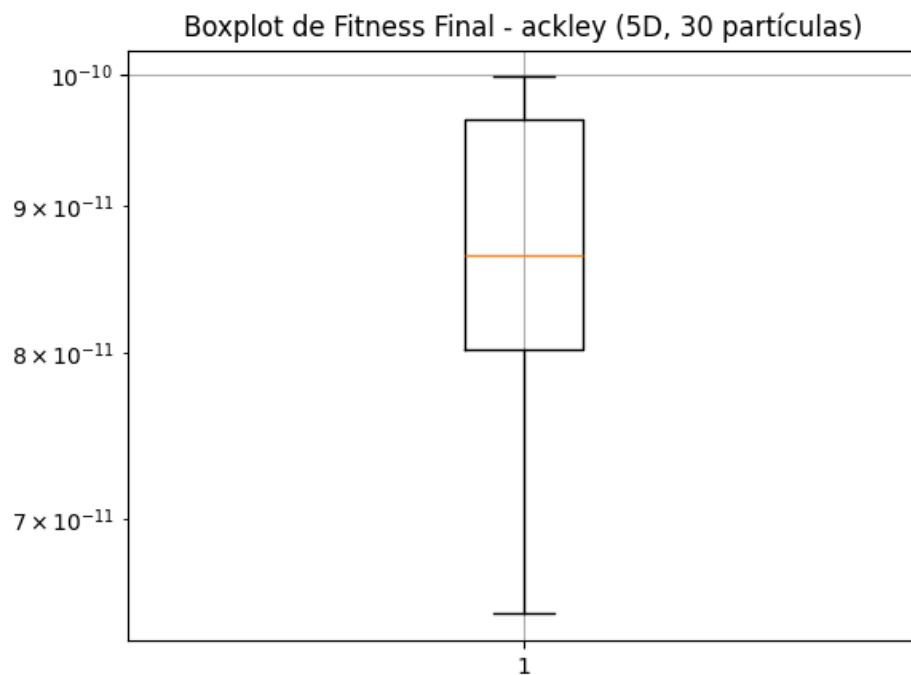


Figura 6. Boxplot dos resultados do PSO para Ackley (5 dimensões)




Figura 7. Boxplot dos resultados do PSO para Ackley (10 dimensões)

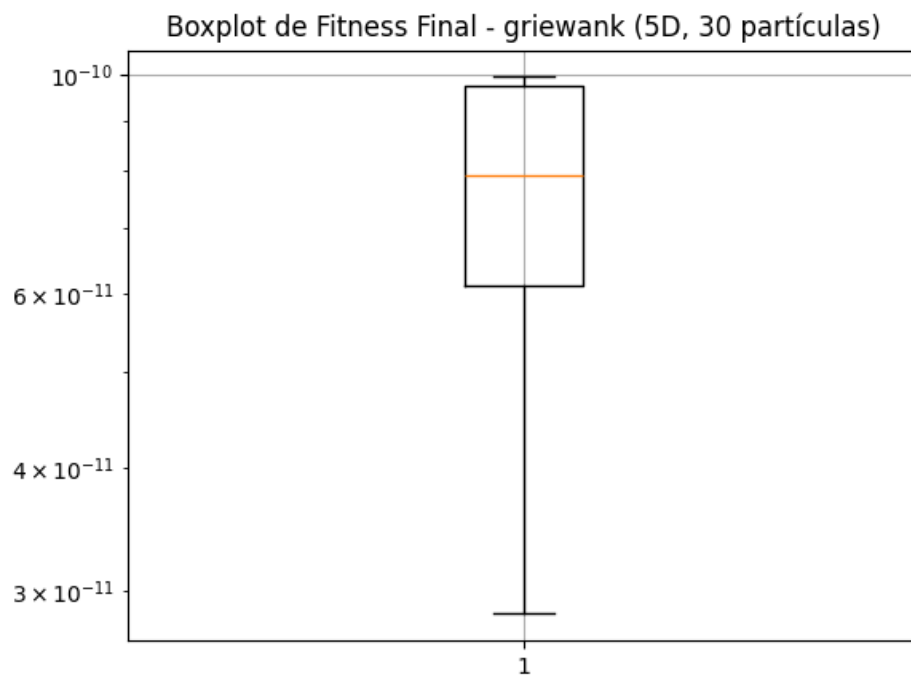


Figura 8. Boxplot dos resultados do PSO para Griewank (5 dimensões)

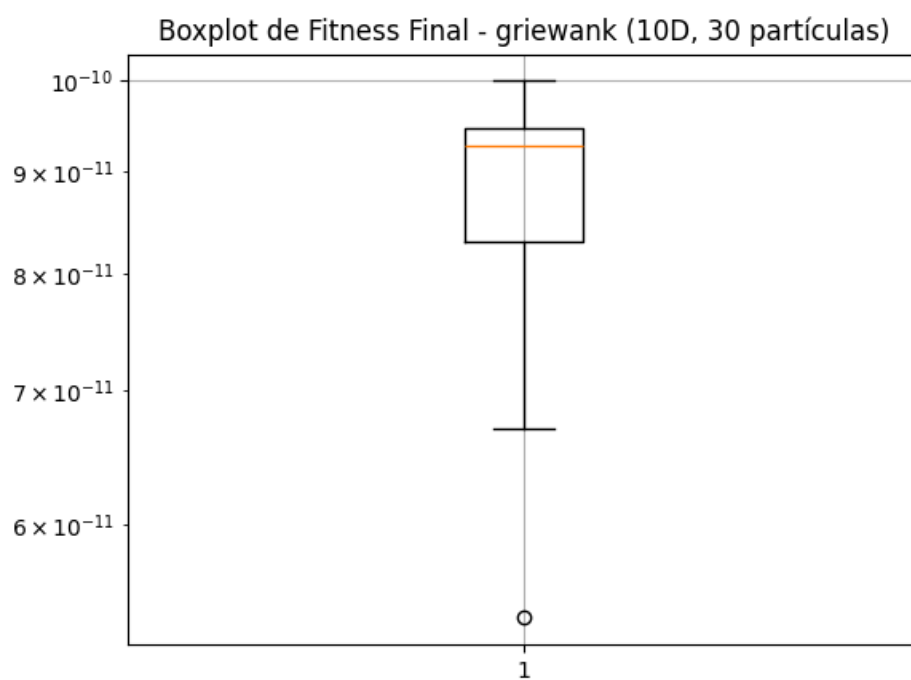


Figura 9. Boxplot dos resultados do PSO para Griewank (10 dimensões)

Tabela 1. Média e Desvio Padrão dos Resultados Obtidos

Função	Dimensões	Média	Desvio Padrão
Ackley	5	0,9792	0,1418
Ackley	10	0,7228	0,1087
Griewank	5	2,5463	0,1992
Griewank	10	3,7791	0,1608

4. Análise dos Resultados Obtidos

A análise dos resultados evidencia que o PSO apresenta desempenho robusto na otimização das funções de Ackley e Griewank. Observa-se que, em menor dimensionalidade (5D), o algoritmo converge mais rapidamente e com menor variabilidade entre as execuções. Para 10 dimensões, a convergência torna-se mais lenta, e a variabilidade aumenta, refletindo a maior complexidade do espaço de busca.

Os parâmetros c_1 e c_2 demonstraram ser eficazes, promovendo um bom equilíbrio entre exploração e intensificação. Aumentar o número de partículas ou de iterações pode melhorar ainda mais a qualidade das soluções em instâncias mais complexas.

5. Conclusões e Trabalhos Futuros

Este trabalho apresentou uma implementação do algoritmo **Particle Swarm Optimization** aplicada à otimização das funções de Ackley e Griewank. Os resultados obtidos demonstram a eficácia do PSO na obtenção de soluções de alta qualidade, especialmente em problemas de menor dimensão.

Como trabalhos futuros, propõe-se:

- Avaliar o PSO em outras funções de benchmark;
- Investigar o impacto da variação dinâmica dos parâmetros;
- Comparar o PSO com outros algoritmos metaheurísticos, como Algoritmos Genéticos e Simulated Annealing;
- Aplicar o PSO em problemas reais de otimização;
- Estudar variantes do algoritmo, como PSO com topologias de vizinhança ou versões híbridas.

Referências

Kennedy, J. and Eberhart, R. (1995). Particle swarm optimization. In *Proceedings of ICNN'95-international conference on neural networks*, volume 4, pages 1942–1948. iee.