

Particle Swarm Optimization

Um estudo sobre o algoritmo PSO

César Eduardo de Souza¹,
Guilherme Diel¹

¹Departamento de Ciência da Computação
Universidade do Estado de Santa Catarina (UDESC) – Joinville, SC – Brazil

{cesar.souza, guilherme.diel}@edu.udesc.br

Resumo. Algoritmos heurísticos são fundamentais para a busca de soluções satisfatórias em problemas complexos de otimização. Um dos métodos mais populares é o **Particle Swarm Optimization** (PSO), inspirado no comportamento coletivo de enxames naturais. Este algoritmo é capaz de resolver problemas NP-Hard e NP-Completo, como funções de benchmark em otimização contínua. Neste trabalho, apresentamos uma implementação do **PSO** para otimização das funções de Ackley e Griewank, analisando o desempenho do algoritmo em diferentes dimensões e discutindo possíveis aplicações futuras e comparações com outras abordagens.

1. Introdução

A busca por soluções eficientes para problemas de otimização combinatória e contínua motivou o desenvolvimento de diversos algoritmos heurísticos e metaheurísticos. Entre eles, destaca-se o **Particle Swarm Optimization** (PSO), proposto por Kennedy e Eberhart em 1995, inspirado no comportamento social de pássaros e cardumes.

O PSO é amplamente utilizado para resolver problemas de otimização devido à sua simplicidade, facilidade de implementação e capacidade de convergência para soluções de alta qualidade. O algoritmo consiste em um conjunto de partículas (soluções candidatas) que exploram o espaço de busca, ajustando suas posições com base em suas experiências individuais e coletivas.

Neste trabalho, investigamos o desempenho do PSO na otimização das funções de Ackley e Griewank, que são funções de benchmark clássicas em otimização contínua. Avaliamos o comportamento do algoritmo em diferentes dimensões e discutimos os resultados obtidos.

Este relatório está organizado da seguinte maneira: a seção 2 apresenta a metodologia de desenvolvimento e a descrição do algoritmo PSO. Em seguida, na seção 3, são abordados os experimentos realizados e os resultados obtidos. A seção 4 discute a análise dos resultados e, por fim, a seção 5 apresenta as conclusões e sugestões para trabalhos futuros.

2. Metodologia de Desenvolvimento

O algoritmo **Particle Swarm Optimization** (PSO) funciona da seguinte forma:

1. Inicializar uma população de partículas com posições e velocidades aleatórias no espaço de busca.

2. Para cada partícula, avaliar a função objetivo na posição atual.
3. Atualizar a melhor posição individual (*pbest*) e a melhor posição global (*gbest*).
4. Atualizar a velocidade e a posição de cada partícula de acordo com as equações:

$$v_i(t+1) = wv_i(t) + c_1r_1(pbest_i - x_i(t)) + c_2r_2(gbest - x_i(t)) \quad (1)$$

$$x_i(t+1) = x_i(t) + v_i(t+1) \quad (2)$$

onde w é o fator de inércia, c_1 e c_2 são os coeficientes cognitivo e social, e r_1 , r_2 são números aleatórios em $[0, 1]$.

5. Repetir os passos 2 a 4 até atingir o critério de parada (número máximo de iterações ou tolerância).

A implementação foi realizada em *Python*, utilizando a biblioteca *Numpy* para operações vetoriais e *Matplotlib* para visualização dos resultados.

imgs/pso_diagram.png

Figura 1. Diagrama do algoritmo de Particle Swarm Optimization

3. Descrição de Experimentos/Simulações e Resultados Obtidos

Os experimentos foram realizados utilizando as funções de Ackley e Griewank, com as seguintes configurações:

- Número de partículas: 30
- Dimensões: 5 e 10
- Número de execuções: 10 para cada configuração
- Coeficientes: $c_1 = c_2 = 2.05$, fator de inércia $w = 0.7$
- Critério de parada: tolerância $1e - 10$ ou número máximo de iterações

Para cada dimensão, foi gerado um gráfico de convergência mostrando a média do fitness ao longo das iterações. As Figuras ?? e ?? apresentam os resultados para 5 e 10 dimensões, respectivamente.



Figura 2. Convergência do PSO para Ackley (5 dimensões)




Figura 3. Convergência do PSO para Ackley (10 dimensões)

Os resultados mostram que o PSO foi capaz de encontrar soluções próximas do ótimo global em ambas as dimensões, com convergência mais rápida para 5 dimensões.

Além disso, é possível verificar a seguinte tabela com média e desvio padrão de 30 execuções do experimento, apontados pelos consecutivos boxplots.

A tabela confirma o que os gráficos mostraram, de maneira que mostra o exponencial como o melhor resultado para o menor arquivo, enquanto o linear foi o melhor resultado para o maior arquivo.

Tabela 1. Média e Desvio Padrão dos Resultados Obtidos

Função	Dimensões	Média	Desvio Padrão
Ackley	5	0.9792	0.1418
Ackley	10	0.7228	0.1087
Griewank	5	2.5463	0.1992
Griewank	10	3.7791	0.1608

4. Análise dos resultados obtidos.

A análise dos resultados evidencia que o PSO apresenta desempenho robusto na otimização das funções de Ackley e Griewank. Observa-se que, para menor dimensionalidade (5D), o algoritmo converge mais rapidamente e com menor variabilidade entre as execuções. Para 10 dimensões, a convergência é mais lenta e a variabilidade dos resultados aumenta, refletindo a maior complexidade do espaço de busca.

O ajuste dos parâmetros c_1 e c_2 mostrou-se adequado, promovendo um equilíbrio entre exploração e intensificação. O aumento do número de partículas ou de iterações pode contribuir para uma convergência ainda mais próxima do ótimo em instâncias de maior dimensão.

5. Conclusões e Trabalhos Futuros

Neste trabalho, foi apresentada uma implementação do algoritmo **Particle Swarm Optimization** para otimização das funções de Ackley e Griewank. Os experimentos demonstraram a eficácia do PSO em encontrar soluções de alta qualidade, especialmente em espaços de menor dimensão.

Como trabalhos futuros, propõe-se a avaliação do PSO em outras funções de benchmark, a análise do impacto de diferentes estratégias de parametrização (como variação dinâmica dos coeficientes) e a comparação com outros algoritmos metaheurísticos, como Algoritmos Genéticos e Simulated Annealing.

Além disso, a aplicação do PSO em problemas reais de otimização, bem como o estudo de variantes do algoritmo (como PSO com topologias de vizinhança ou versões híbridas), constitui uma linha promissora para pesquisas futuras.